

小 ν 下异方差 Student- t 的 scale-head 优化问题

两个梯度失衡、两个候选修复及当前证据边界

Internal technical note for *Much Ado About Noising*

2026-09-08

结论先行。数据上的联合 Student- t 拟合偏好个位数 ν ，但端到端策略训练中，小 ν 会让共享特征收到的 scale-path 梯度相对 mean-path 快速衰减；现有 softplus scale 参数化还会对较大的绝对尺度施加额外链式衰减。这两个问题是不同的：前者来自 Student- t score 中的 $\nu/(\nu+q)$ ，后者来自 $\partial \log \sigma / \partial u$ 。候选方案 A 用 detached-mean Gaussian auxiliary 恢复 scale 梯度，并应配合直接预测 $s = \log \sigma$ ；候选方案 B 改用 scaled energy proper score，同样使用 log-scale 参数化。方案 B 对 mean gradient 有界，因而比 Gaussian 更抗长尾，但它不具有 Student- t NLL 的 redescending influence，不能表述成“等价的 Student- t 长尾抑制”。

1 问题设置与记号

给定输入 o 、动作块标签 $a \in \mathbb{R}^d$ ，网络共享特征为 $x = h_\theta(o)$ ，两个 head 分别预测位置 $\mu = \mu_\theta(x)$ 与标量尺度 $\sigma = \sigma_\theta(x) > 0$ 。令

$$r = \mu - a, \quad S = \|r\|^2, \quad q = \frac{S}{\sigma^2}, \quad s = \log \sigma. \quad (1)$$

当前 GR00T action chunk 在 Bridge/Fractal 上有 $d = 8 \times 7 = 56$ 个有效训练坐标；GR1 为 $d = 8 \times 29 = 232$ 。以下统一使用每坐标平均的 joint Student- t negative log-likelihood（省略与 μ, σ 无关的常数）：

$$\ell_T(\mu, s; \nu) = \frac{\nu + d}{2d} \log \left(1 + \frac{q}{\nu} \right) + s. \quad (2)$$

对应的 heteroscedastic Gaussian (HG) loss 为

$$\ell_G(\mu, s) = \frac{q}{2d} + s. \quad (3)$$

这里的 ν 是整个 d 维向量共享 radial scale 的 joint- t 自由度，不是逐坐标自由度的求和。

为什么现在才暴露问题。 冻结现有策略输出后重新做完整 joint likelihood calibration，得到的描述性最优值为 Fractal $\hat{\nu} = 6.53$ 、Bridge 9.82、RoboCasa-GR1 5.66；训练中表现较好的设置却分别使用了 224, 224, 928。这不意味着统计拟合错了，而是说明“固定预测上的 density fit”和“共享神经网络的端到端优化条件”不是同一个问题。

2 问题一：小 ν 让 scale path 被 mean path 抢占

2.1 精确梯度恒等式

对式 (2) 求导，记 $w = (\nu + d)/(\nu + q)$ ，得到

$$\nabla_\mu \ell_T = \frac{w}{d\sigma^2} r, \quad \frac{\partial \ell_T}{\partial s} = 1 - \frac{wq}{d} = \frac{\nu(d-q)}{d(\nu+q)}. \quad (4)$$

Gaussian loss 的对应梯度为

$$\nabla_\mu \ell_G = \frac{r}{d\sigma^2}, \quad \frac{\partial \ell_G}{\partial s} = 1 - \frac{q}{d}. \quad (5)$$

因此，在相同的特征、head、残差与尺度上有两个精确关系：

$$\nabla_\mu \ell_T = w \nabla_\mu \ell_G, \quad \frac{\partial \ell_T}{\partial s} = \frac{\nu}{\nu+q} \frac{\partial \ell_G}{\partial s}. \quad (6)$$

进一步，把两个 head 对共享特征 x 的 Jacobian 分别记作 J_μ, J_s ，则

$$g_x^\mu = J_\mu^\top \nabla_\mu \ell_T, \quad g_x^\sigma = J_s^\top \frac{\partial \ell_T}{\partial s}. \quad (7)$$

相对于 Gaussian，在每个样本上 scale/mean 的权重比额外乘上

$$\frac{\nu/(\nu+q)}{(\nu+d)/(\nu+q)} = \boxed{\frac{\nu}{\nu+d}}. \quad (8)$$

这就是“抢占”的准确含义：它不要求 mean gradient 绝对爆炸，而是 scale path 相对 mean path 系统性变弱。对 $d = 56$, $\nu = 224, 14, 7$ 的相对系数分别为 0.80, 0.20, 0.111；对 $d = 232$, $\nu \approx 6$ ，仅约为 0.025。

2.2 scale correction 还具有方向不对称

式 (4) 给出

$$-\frac{\nu}{d} \leq \frac{\partial \ell_T}{\partial s} \leq 1. \quad (9)$$

当 $q \rightarrow \infty$ 、即尺度被严重低估时，梯度下降需要增加 s ，但其驱动力的幅值最多只有 ν/d ；当 $q \rightarrow 0$ 、尺度过大时，减小 s 的驱动力却可达到 1。所以 $d = 56$, $\nu = 7$ 时，增加尺度一侧最大只有 0.125。在每样本尺度最优值 $q = d$ 附近，曲率为

$$\left. \frac{\partial^2 \ell_T}{\partial s^2} \right|_{q=d} = \frac{2\nu}{\nu+d}, \quad (10)$$

从 $\nu = 224$ 的 1.60 降到 $\nu = 7$ 的 0.222，scale optimization 变平 7.2 $\times$ 。

2.3 真实模型上的梯度证据

表 1 使用 Fractal 训练中的两个真实 checkpoint，冻结相同的输入、dropout、共享特征、head、预测与标签，仅反事实替换 ν ，分别 detach 两个分支后测量共享特征 x 收到的 per-example 梯度。它直接验证了式 (8) 在实际网络中的后果。

Table 1: 小 ν 显著压缩共享特征上的 **scale-path** 梯度。数值为 128 个 Fractal 训练样本的 per-example feature-gradient；不是 rollout 成功率，也不是 Adam 更新量。

Checkpoint	ν	mean $\ g_x^\mu\ $	mean $\ g_x^\sigma\ $	median $\ g_x^\sigma\ / \ g_x^\mu\ $
10k	224	0.11221	0.01987	0.14624
10k	7	0.12039	0.00316	0.02031
12k	224	0.12129	0.02788	0.18126
12k	7	0.12605	0.00424	0.02518

从 $224 \rightarrow 7$ ，scale-path mean norm 分别降至原来的 15.9% 与 15.2%，而 mean-path norm 反而上升 7.3% 与 3.9%；median branch ratio 分别缩小约 7.20 $\times$ 与 7.20 $\times$ 。这与纯解析预测一致。

一个必要 caveat。 单样本的 scale score 会随 ν 下降，但 batch 内正负 scale gradients 可能发生不同程度的抵消。因此，求和后的参数梯度 *norm* 不保证单调下降：在 1,024 样本 audit 中， $128 \rightarrow 64$ 使 sigma-decoder norm 从 0.10044 降至 0.02496，并旋转 71.78°；而 $32 \rightarrow 14$ 却从 0.03026 升至 0.05140。后者不是对推导的反例，而是提醒我们：式 (8) 是逐样本、逐路径的恒等式，最终优化还受 cancellation、Jacobian 与 Adam 影响。

3 问题二：大绝对尺度在 raw sigma head 中被额外降权

3.1 问题来自参数化，而不是 proper likelihood 本身

若网络直接预测 $s = \log \sigma$ 并令 $\sigma = e^s$ ，则式 (4) 只依赖标准化能量 q_0 。同时把 r 与 σ 放大相同倍数不会改变 $\partial \ell / \partial s$ ，这正是所需的尺度等变性。

当前实现则先输出 raw value u ，再使用

$$\sigma = \text{softplus}(u) + \varepsilon, \text{quad}\varepsilon = 10^{-3}. \quad (11)$$

链式法则给出

$$\frac{\partial \ell}{\partial u} = \frac{\partial \ell}{\partial s} \underbrace{\frac{\text{sigmoid}(u)}{\sigma}}_{\partial \log \sigma / \partial u}. \quad (12)$$




Figure 1: 两个梯度问题与两种 robust influence。 (a) 真实 GR00T/Fractal checkpoint 上, 减小 ν/d 后共享特征收到的 scale/mean 梯度比快速下降。(b) Student- t 的 log-scale score 在 $q/d \gg 1$ 时饱和于 $-\nu/d$ 。(c) 直接预测 log scale 保持单位链式因子; softplus raw scale 在大 σ 时近似按 $1/\sigma$ 衰减。(d) Gaussian mean influence 随残差无界增长, Student- t redescends 到零; scaled energy influence 有界但不 redescend。只有 (a) 是真实模型测量, (b-d) 是解析或固定随机种子的 Monte Carlo loss 诊断。

当 σ 较大时, $\text{sigmoid}(u) \simeq 1$, 故 raw-head 梯度近似按 $1/\sigma$ 衰减。换言之, 大尺度样本虽然有更大的绝对残差 S , likelihood 中的 inverse-scale normalization 会把它抵消; softplus raw 参数化又额外把 log-scale score 除以约 σ 。

Table 2: 同样的相对误差, 不同的绝对尺度。 两个样本均有 $\text{residual RMS}/\sigma = 2$, 故 $q/d = 4$; 取 $d = 56, \nu = 14$ 。

Residual RMS	σ	$\partial \ell_T / \partial s$	$\partial \ell_T / \partial \sigma$	$\partial \ell_T / \partial u$
2	1	-0.1765	-0.1765	-0.1115
10	5	-0.1765	-0.0353	-0.0351

第二个样本的 squared residual 大 $25\times$, 但 direct- σ gradient 只有 $1/5$, softplus raw-head gradient 只有约 31%。若直接预测 log scale, 则两者都收到 -0.1765 。这说明“大的真实噪声尺度应给 scale head 更强监督”不会从现有参数化自动发生。

证据边界。 该现象是精确链式法则, 并通过 synthetic autograd scale test 验证; 它目前不是一个已经由 rollout 因果隔离的性能解释。真实 checkpoint 的 σ P10/P50/P90 为 Fractal 0.114/0.184/0.301、Bridge 0.136/0.205/0.290、GR1 0.0129/0.0239/0.1035。这些数据证明 scale 确实跨样本变化, 但不能单独证明 softplus attenuation 是当前性能瓶颈。因此后续 ablation 必须把 score 与参数化拆开。

4 方案 A: detached-mean HG auxiliary 恢复 scale supervision

用户讨论中的“ ν detach”在实现上应准确写成 μ **detach**: ν 本来就是固定常数, 不需要 detach 的计算图。定义

$$\ell_A = \ell_T(\mu, s; \nu) + \lambda \ell_G(\text{sg}[\mu], s), \quad \lambda \geq 0. \quad (13)$$

stop-gradient 只作用于 auxiliary 的 μ ; 两个项共享同一个 σ 。

4.1 为什么梯度方向是对的

式 (6) 立即给出

$$\nabla_\mu \ell_A = \nabla_\mu \ell_T, \quad (14)$$

$$\frac{\partial \ell_A}{\partial s} = \left(\frac{\nu}{\nu + q} + \lambda \right) \left(1 - \frac{q}{d} \right). \quad (15)$$

所以 auxiliary 对 direct mean prediction 的梯度严格为零, Student- t 的 robust mean update 完全保留; 而 scale 梯度只乘上一个始终为正的系数, 其符号仍由 $d - q$ 决定: $q > d$ 时增大 σ , $q < d$ 时减小 σ 。对单个非零残差, stationary point 仍是 $q = d$, 即 $\sigma^2 = S/d$ 。在该点的 log-scale 曲率变为

$$\frac{\partial^2 \ell_A}{\partial s^2} \Big|_{q=d} = \frac{2\nu}{\nu + d} + 2\lambda. \quad (16)$$

例如 $d = 56, \nu = 14, \lambda = 1$ 时, 从 0.4 提升至 2.4, 恰好恢复约 $6\times$ 的局部 scale conditioning。

4.2 它补偿了什么，又没有补偿什么

- **解决问题一**：HG 项没有 $\nu/(\nu+q)$ ，因此直接补回小 ν 丢失的 scale score; detach 保证它不会把 Gaussian 的 unbounded mean gradient 加回去。
- **要解决问题二，仍需 log-scale**：若继续使用 softplus raw head, 式 (12) 仍存在。当前 matched candidate 因此使用 $\sigma = \exp(s)$ ，而不仅仅是添加 auxiliary。
- **它不是纯 Student- t MLE**：stop-gradient 产生的是一个有意设计的联合更新规则，而不是普通标量目标对 (μ, s) 的完整梯度。对共享 conditional $\sigma(o)$ ，HG 与 Student- t 的 population scale optimum 也未必相同。应把它表述为 scale-optimization auxiliary，而不是“仍然精确最大化 Student- t likelihood”。

4.3 已有实验证据

真实 8-GPU Fractal 首批数据上， $d = 56, \nu = 14, \lambda = 1$ ：HT-only 的 mean absolute $\log \sigma$ gradient 为 0.03932，加入 auxiliary 后为 0.25671，提升 6.53 $\times$ ，与式 (16) 的约 6 $\times$ 局部预测一致。单元测试同时验证：(i) auxiliary 到 μ 与 mean-only 参数的梯度严格为零；(ii) 到 σ 与共享特征的梯度非零；(iii) combined direct-mean gradient 与 HT-only 完全相同。该证据证明了梯度机制，尚未证明最终 closed-loop success 提升。

5 方案 B: scaled energy proper score

5.1 完整定义与严格 propriety

对任意非退化、具有有限一阶矩的预测分布 P ，定义

$$A(P, y) = \mathbb{E}_{X \sim P} \|X - y\|, \quad B(P) = \mathbb{E}_{X, X' \sim P} \|X - X'\|, \quad (17)$$

以及待最小化的 scaled energy score

$$\ell_{SE}(P, y) = \frac{2A(P, y)}{B(P)} + \log B(P). \quad (18)$$

令真实分布为 Q ， $C = B(Q)$ ， $D_E(P, Q) = 2\mathbb{E} \|X - Y\| - B(P) - C$ 为 energy distance，则

$$\mathbb{E}_Q \ell_{SE}(P, Y) - \mathbb{E}_Q \ell_{SE}(Q, Y) = \frac{D_E(P, Q)}{B(P)} + \frac{C}{B(P)} - 1 + \log \frac{B(P)}{C} \geq 0. \quad (19)$$

第一项由 energy distance 非负；第二部分在 $B(P) = C$ 时取唯一最小值。故该 score 严格 proper。这里要区分：score 可用于广泛的 sampled distributions，但我们的 policy family 若只输出 (μ, σ) 与固定形状 Student- t base distribution，表达能力仍限于这个 location-scale family，并不是“自动表达任意分布”。

5.2 固定 ν joint- t 的可训练形式

令

$$X = \mu(o) + e^{s(o)} U, \quad U \sim t_\nu(0, I_d), \quad \nu > 1, \quad (20)$$

且 $\kappa_{\nu, d} = \mathbb{E} \|U - U'\|$ 。因为 $B(P) = e^s \kappa_{\nu, d}$ ，省略固定常数 $\log \kappa$ 后得到

$$\ell_{SE}(\mu, s; y) = \frac{2}{\kappa_{\nu, d}} \mathbb{E}_U \|(y - \mu)e^{-s} - U\| + s. \quad (21)$$

它只需在 action vector 空间采样 U ，不把噪声喂给 policy，也不需要重复网络前向。实验原型固定 $\nu = 14, d = 56$ ，用 $K = 16$ 个 joint- t samples；一个 chi-square denominator 由整个 56 维向量共享。

5.3 为什么它能帮助两个 scale 问题

记 $z = (y - \mu)e^{-s}$ 、 $v(U) = (z - U)/\|z - U\|$ 。则

$$\nabla_\mu \ell_{SE} = -\frac{2}{\kappa e^s} \mathbb{E}_U [v(U)], \quad \frac{\partial \ell_{SE}}{\partial s} = 1 - \frac{2}{\kappa} \mathbb{E}_U [z^\top v(U)]. \quad (22)$$

它有两个关键性质：

1. 不存在小 ν 的 **scale-score cap**。式 (22) 没有 $\nu/(\nu + q)$ 乘子；当 $\|z\|$ 很大时，scale gradient 的负向幅值近似随 $\|z\|$ 线性增长，能够强力纠正被严重低估的尺度。
2. 配合 $s = \log \sigma$ 后精确尺度等变。同时把 $y - \mu$ 与 σ 乘以 $c > 0$ ， z 与 $\partial \ell / \partial s$ 不变；loss 只增加常数 $\log c$ 。同一组 Monte Carlo base samples 下该性质逐 batch 精确成立。

合成 autograd test 在相同标准化残差下得到：residual $\text{RMS}/\sigma = 2/1$ 与 $10/5$ 的 $\partial \ell_{SE} / \partial s$ 均为 -1.352374 。这直接验证了方案 B 对问题二的尺度平衡；analytic constant、mask、joint- t sampling、随机数隔离和 propriety identity 的单元测试均通过。

5.4 它是否像 Student- t 一样抑制长尾？

答案是：有 **bounded mean influence**，但不是相同的抑制机制。由式 (22)，

$$\|\nabla_{\mu} \ell_{SE}\| \leq \frac{2}{\kappa \sigma}. \quad (23)$$

因此 outlier 再大，mean gradient 也不会像 Gaussian 那样无界增长。可是当 $\|r\|/\sigma \rightarrow \infty$ 时，scaled energy 的 mean influence 趋近一个非零常数；Student- t NLL 则按 $1/\|r\|$ 衰减到零。表 3 总结了差别。

Table 3: 三种 score 的尾部 influence。 令 $R = \|r\|/\sigma \rightarrow \infty$ ；忽略与 R 无关的正常数。

Score	Mean influence	Scale correction	尾部解释
Gaussian NLL	$O(R)$ ，无界	$O(R^2)$	outlier 主导 mean 与 scale redescending；极端样本近似被忽略
Student- t NLL	$O(1/R) \rightarrow 0$	饱和于 $-\nu/d$	
Scaled energy	$O(1)$ ，有界	$O(R)$	限制 mean，但仍让极端样本校正 scale

所以方案 B 相对 Gaussian 确实具有 *robust mean fitting*，但不能宣称覆盖或等价于 Student- t 的 redescending robustness。它的 scale gradient 也不是 bounded-robust：真实 contamination 可能推动 σ 变大。这既可能是优点（修复 under-estimated conditional scale），也可能是风险（把不可约 outlier 吸收到 scale）；必须由 calibration 与 closed-loop ablation 判断。

6 两个方案如何选择与验证

Table 4: 两个候选方案的功能边界。

	A: HT + HG(sg[μ]) + log-scale	B: scaled energy + log-scale
保留 Student- t MLE	Mean gradient 保留；联合更新不再是纯 MLE	否；改为严格 proper energy score
小 ν scale starvation	HG 项直接补偿	没有 $\nu/(\nu + q)$ scale cap
绝对尺度平衡	需要 exp/log-scale 才完整解决	exp/log-scale 下精确等变
Mean-tail influence	Student- t redescending	bounded，但不 redescending
实现成本	无采样；一个 auxiliary	K 个 action-space samples；仍仅一次网络前向
主要风险	HG scale 项可能吸收 contamination	scale influence 对极端残差无界

最干净的实验不是直接比较两个新方案，而是做一个能拆开因果因素的 matched ablation：

1. native HT + softplus（现有参考）；
2. native HT + exp/log-scale（只测问题二）；
3. HT + detached-mean HG + exp（同时补偿问题一、二）；
4. scaled energy + exp（方案 B）；
5. scaled energy + softplus（确认方案 B 的收益是否依赖 log-scale）。

所有 arm 必须共享初始 σ_0 、data order、batch、optimizer、训练步数和评价 scenes。训练期同时记录 $\|g_x^o\|/\|g_x^u\|$ 、 q/d 、 σ quantiles、scale-score 正负抵消与 tail gradient mass；最终同时报告 rollout success、held-out NLL/energy score 与 scale calibration。否则“新 score 更好”无法区分是 score、参数化还是初始化造成的。

Table 5: 可安全写入论文的结论与证据状态。

Claim	Evidence	Status
小 ν 相对抑制 scale path	精确梯度恒等式; 两个真实 checkpoint 的 feature-gradient audit	Supported
scale starvation 是性能下降的唯一原因	尚无 matched closed-loop causal ablation	Needs evidence
softplus raw head 不具绝对尺度等变性	精确链式法则; 2/1 vs. 10/5 controlled test	Supported
detached-mean HG 补偿 scale 且不改 direct mean gradient	解析式; 单元测试; 真实首批梯度 0.03932 $\rightarrow$ 0.25671	Supported
HG auxiliary 保持纯 Student- t MLE	stop-gradient 与 Gaussian scale target 改变联合估计	False; do not claim
scaled energy 是 strictly proper	energy-distance risk-gap identity	Supported
scaled energy 抑制长尾	mean influence bounded; 但不 redescend, scale influence not bounded	Qualified
任一新方案提高机器人成功率	matched training/evaluation 尚未完成	Needs evidence

7 Claim-evidence map 与当前结论

最终判断。 目前最强的机制结论不是“理论最优 ν 应直接拿来训练”，而是：当 ν/d 很小时，标准 *joint Student- t NLL* 同时改变 *mean sample weighting* 与 *scale-head conditioning*；现有 *raw-scale* 参数化又引入第二层尺度不平衡。方案 A 是保守修复：保留 Student- t 的 mean robustness，专门补 scale；方案 B 是更统一的 proper-score 修复：用一个 sampled score 同时获得 log-scale 等变性与 bounded mean influence，但放弃 redescending。论文在 closed-loop ablation 完成前，应把二者称为候选优化方案，而不是已经建立的最终算法优势。

Reviewer-style self-review

- **Contribution:** 两个失衡是否被明确拆分为 score coupling 与 parameterization coupling? ——是。
- **Clarity:** 每个方案是否写清 motivation、definition、gradient 与 limitation? ——是。
- **Experimental strength:** 是否已有多个 seed 的 rollout 因果证据? ——否，需要 matched ablation。
- **Evaluation completeness:** 是否拆开 auxiliary、score、exp/softplus 与初始化? ——已给出必需设计，尚待执行。
- **Soundness:** 是否错误宣称 auxiliary 仍为纯 MLE, 或 scaled energy 等价于 Student- t redescending? ——没有；两点均明确否定。

Artifacts and references

- Shared-feature gradient audit: analysis/diagnostics/nu_recipe_debug/shared_feature_gradients/.
- ν switch audit: analysis/diagnostics/nu_gradient_switch/RESULTS.md.
- Auxiliary implementation and tests: scripts/cluster/nu14_gaussian_aux_launch.py, scripts/cluster/test_nu14_gaussian_aux.py.
- Scaled energy derivation and tests: analysis/diagnostics/nu_recipe_debug/SCALED_ENERGY_DESIGN.md, scripts/test_scaled_energy_score.py.
- J. E. Bolin and J. Wallin. *Local scale invariance and robustness of proper scoring rules*, 2020.
- T. Gneiting and A. E. Raftery. *Strictly proper scoring rules, prediction, and estimation*, JASA, 2007.
- K. L. Lange, R. J. A. Little, and J. M. G. Taylor. *Robust statistical modeling using the t distribution*, JASA, 1989.
- M. Seitzer et al. *On the pitfalls of heteroscedastic uncertainty estimation with probabilistic neural networks*, ICLR, 2022.